



# **Modelo no lineal de la hemodinámica cerebral utilizando Redes Neuronales Profundas**

**Informe Nº 3**

**Propuesta Final**

Nombre: Cristóbal Vásquez Fernández

Rut: 17.708.318-6

Carrera: Ingeniería Civil Informática

Año de egreso: 2016

Fono: 760 60 764

E-mail: cristobal.vasquez@usach.cl

Profesor patrocinador: Dr. Max Chacón

## Resumen

Muchos de los procesos encefálicos que producen la muerte de los pacientes que los presentan están mediados por la presión del cerebro, específicamente por hipertensión intracraneal. El concepto de autorregulación sanguínea cerebral estudia los mecanismos fisiológicos que se encargan de mantener el **flujo sanguíneo cerebral en un nivel adecuado**. En este contexto es que se propone un modelo no lineal para representar la hemodinámica cerebral utilizando Redes Neuronales Profundas, adicionalmente se compararán los resultados de este modelo con los actuales que utilizan SVM. El propósito es mejorar estos modelos en términos de eficiencia en tiempos de entrenamiento y precisión.

## Índice de contenido

1. Objetivos del proyecto .....	1
1.1. Objetivo general .....	1
1.2. Objetivos específicos.....	1
2. Descripción del problema.....	1
2.1. Motivación .....	1
2.2. Estado del arte.....	2
2.3. Definición del problema .....	3
3. Análisis de la solución propuesta .....	4
3.1. Características de la solución.....	4
3.2. Propósitos de la solución .....	5
3.3. Alcances y limitaciones de la solución.....	5
4. Metodología, herramientas y ambiente de desarrollo .....	6
4.1. Metodología a usar .....	6
4.2. Herramientas de desarrollo .....	7
4.3. Ambiente de desarrollo.....	7
5. Plan de trabajo .....	8
6. Referencias .....	8
7. Apéndice.....	10
7.1. Glosario .....	10
7.2. Enfoques de solución.....	11
7.3. Justificación del enfoque seleccionado .....	12
7.4. Carta gantt.....	12

# 1. Objetivos del proyecto

## 1.1. Objetivo general

Modelar eficientemente la hemodinámica cerebral basándose en un comportamiento no lineal, esto en términos de precisión y disminuyendo los tiempos de entrenamiento de los modelos. Para lo cual se utilizará RNP analizando el rendimiento y precisión del modelo.

## 1.2. Objetivos específicos

- Realizar un estudio detallado en la literatura relacionada con el tema de modelos de predicción en series de tiempo, para determinar que arquitecturas de redes neuronales profundas podrían mejorar los resultados obtenidos por una SVM (Máquina de Vectores de Soporte).
- Escoger el lenguaje de programación basando la decisión en los *packages* de *deep learning* disponibles en los lenguajes *Matlab* y *R*.
- Diseñar e implementar uno o más modelos no lineales, para así compararlos en base a los resultados obtenidos, utilizando para este propósito el error cuadrático medio normalizado y el coeficiente de correlación.
- Evaluar los modelos generados y seleccionar el que posea mejores resultados que la SVM que se encuentra actualmente (Chacón, 2010).
- Realizar un análisis estadístico del modelo o los modelos generados, para expresar la precisión de estos en base a las siguientes medidas:
  - Coeficiente de correlación
  - Error cuadrático medio normalizado

# 2. Descripción del problema

## 2.1. Motivación

En Chile, la principal causa de muerte se debe a patología del sistema cardiovascular y corresponde a 27% de las defunciones por grandes grupos de causa de muerte. Dentro de ésta, los accidentes cerebrovasculares (ACV) corresponden a la primera causa específica de muerte, representando 9% del total de defunciones el año 2010 (Oberreuter, 2014). De esta manera se hace relevante el estudio del fenómeno de autorregulación del flujo sanguíneo cerebral, ya que por medio de este se podrían realizar diagnósticos y tratamientos con mayor efectividad ante enfermedades de este tipo (Panerai, 1997).

La autorregulación cerebral aborda los mecanismos fisiológicos que se preocupan de mantener el flujo sanguíneo en un nivel apropiado, en especial ante cambios de presión. En este contexto se presentan dos enfoques para la evaluación de la autorregulación cerebral, el estático y dinámico. El primero se dedica a evaluar el efecto total (eficiencia) de la acción de autorregulación, es decir, el cambio en la resistencia vascular cerebral (RVC), en respuesta a la manipulación de la presión arterial (PAM), pero no indica el momento en que se produce el cambio en RVC (latencia) (Tiecks, Lam, Aaslid, 1995). El segundo enfoque surge por Aaslid et al. introducir un método no invasivo utilizando un Ultrasonografía Doppler Transcraneal (UDT) para la evaluación de la autorregulación cerebral, este enfoque provee información acerca de la latencia a diferencia del enfoque estático, lo cual puede ser relevante en ciertas condiciones clínicas como la lesión craneal (Torbey, 2004; Tiecks, Lam, Aaslid, 1995).

El enfoque dinámico para la evaluación de la autorregulación es el que se ha utilizado en este último tiempo, esto dado que se puede apreciar el comportamiento del flujo en el tiempo, tal como se mencionó anteriormente.

El modelo actual vigente de la hemodinámica cerebral está basado en aprendizaje supervisado con SVM, en este contexto la SVM puede modelar fenómenos dinámicos en el tiempos añadiendo recurrencias externas con retardos en el tiempo, sin embargo no existe la SVM de recurrencias internas. A pesar de esto, los resultados que se obtienen con este modelo tienen buena precisión (Corr: 0.909 +- 0.065; ECMN (error cuadrático medio normalizado): 16.50+-10.79), pero pueden seguir mejorando (Chacón, 2009).

Uno de los principales problemas que presenta la SVM está en los tiempos de entrenamiento que puede ascender a 24 horas por sujeto (Burgos, 2014), por lo que se necesita mejorar la eficiencia del modelo en término del tiempo de entrenamiento.

## **2.2.Estado del arte**

Como ya se mencionó anteriormente la introducción del TCD por Aaslid, permite obtener grabaciones continuas de la velocidad del flujo sanguíneo cerebral (VFSC) con una alta resolución temporal, sin embargo la interpretación y aplicación clínica de las mediciones del VFSC no es sencilla. La principal dificultad en la interpretación de la VFSC está en la complejidad de los mecanismos reguladores que controlan el FSC manteniéndolo en niveles adecuados, para que coincida con la oferta y demandas de oxígeno, además de proteger al cerebro ante perturbaciones de la PAM, mecanismo conocido como autorregulación de la presión cerebral (AC) (Paulson, 1990). La segunda influencia dominante en el FSC (además de la PAM) es el  $CO_2$  arterial

( $PaCO_2$ ), que se refiere a menudo como la reactividad cerebrovascular (RCV) (Markwalder, 1984).

Tradicionalmente la AC y RCV han sido evaluadas midiendo cada una separadamente, hasta que se demostró que al inducir hipercapnia, por ejemplo respirando 5% de  $CO_2$  en el aire, a menudo produce cambios significativos en el FSC que podrían confundir la respuesta RCV, debido a una respuesta autorreguladora (AC) (Torbey, 2004; Garvía, 2007). Para hacer frente a este problema, se realizó un modelo dinámico multivariado para así tener en cuenta las influencias simultáneas de la PAM y  $PaCO_2$  en el FSC (Panerai, 2000; Mitsis, 2004).

La mayor parte de los estudios utilizan métodos de dominio de tiempo lineales, (Panerai, 2000; Edwards, 2004), con solo un estudio adoptando modelos que incluyen comportamientos no lineales (Mitsis, 2004). Adicionalmente dos estudios han modelado cambios espontáneos en la PAM y  $PaCO_2$  en descanso (Mitsis, 2004; Simpson, 2000). Simpson analizó la respuesta de la inhalación de 5% de  $CO_2$  en el aire, mientras que Edwards realizó una técnica de dos inhalaciones de 10% de  $CO_2$  para modelar las respuestas durante hipocapnia, hipercapnia y normocapnia (Simpson, 2000; Mitsis, 2004).

De esta manera, el desafío está en el modelamiento no lineal multivariado de las influencias simultáneas de la PAM y  $PaCO_2$  en la VFSC, para lo cual se han adoptado enfoques utilizando; RN *feedforward* (Mitsis, 2004), como también se ha modelado con SVM debido a su mayor robustez para representar series de tiempo en comparación a las RN (Chacón, 2010).

Adicionalmente se ha demostrado que los modelos que consideran como variables de entrada la **PAM y  $pCO_2$** , entrenados con SVM son superiores a las RN en términos de ajuste a un conjunto de datos desconocidos, además de ser más adecuados para medir la influencia del  $pCO_2$  en la VFSC (Chacón, 2009).

Como se puede apreciar en la literatura se ha trabajado con modelos no lineales para la representación del fenómeno de la hemodinámica cerebral, ya que ofrece mejores resultados que los modelos lineales, adicionalmente la SVM genera modelos superiores en términos de ajustes para representar este fenómeno.

### **2.3. Definición del problema**

En el contexto de los modelos no lineales actuales de la hemodinámica cerebral (Chacón, 2009; Mitsis, 2004) ¿Cómo mejorar la precisión y eficiencia en

tiempo de entrenamiento de los modelos no lineales actuales que se utilizan para analizar el fenómeno de la hemodinámica cerebral?

### **3. Análisis de la solución propuesta**

#### **3.1. Características de la solución**

El dominio del problema se encuentra dentro del área de aprendizaje automático (*Machine Learning*). Específicamente se realizará un modelo de la hemodinámica del cerebro utilizando Redes Neuronales Profundas, en el contexto de análisis de series temporales, que en este caso representan la presión sanguínea y flujo sanguíneo cerebral.

Las RNP se han utilizado para modelar fenómenos dinámicos en el tiempo utilizando recurrencias internas para el modelamiento, ejemplos de esto son la predicción de datos financieros (Batres-Estrada, 2015) y la predicción del clima (Liu, 2014). En el último caso se modeló una RNP con una SVM en la capa superior de aprendizaje, obteniendo un modelo con mejor ajuste que la clásica SVM. De esta manera se posee información que motiva la decisión de modelar la hemodinámica cerebral utilizando RNP, para comparar los resultados que se generen con la actual SVM que posee los mejores resultados.

Actualmente existen modelos no lineales que presentan mejores resultados que los modelos lineales, sin embargo estos pueden demorarse mucho en la etapa del entrenamiento (Chacon, 2009; Burgos, 2014).

En cuanto a los sujetos y mediciones se evaluará 16 sujetos saludables con edad de  $31.8 \pm 8.5$  años, los cuales se encuentran en condiciones de laboratorio con temperatura controlada. Ninguno de estos tiene historial de hipertensión, diabetes, migraña, epilepsia, u otro tipo de enfermedad cardiovascular ni neurológica. El estudio fue aprobado por Leicestershire Research Ethics Committee y un consentimiento informado fue obtenido para todos los casos. Los datos de los sujetos de estudio son los mismos utilizados por (Chacón, 2010).

A estos sujetos se les sometió a respirar 5% de  $CO_2$  utilizando una máscara para éste propósito. De esta manera se midió la autorregulación sanguínea en condiciones normales y bajo influencias de  $CO_2$  en el aire, para simular así “enfermedad” en los sujetos.

Para el desarrollo del modelo se tiene considerado modelos estáticos con recurrencias externas (ARX), como el que se utiliza actualmente con la Máquina de Vectores de Soporte (SVM), o alternatively un modelo que considere recurrencias internas lo cual no puede ser realizado con SVM, sin embargo para RNP en el año 2006 se propuso el algoritmo *Greedy learning* (Hinton, 2006) para aprendizaje no supervisado en redes profundas con recurrencias internas. Si bien ambos enfoques pueden representar fenómenos dinámicos en el tiempo, la SVM lo realiza con recurrencias externas y la RNP puede hacerlo con recurrencias internas.

### **3.2. Propósitos de la solución**

El propósito es mejorar la precisión y eficiencia en tiempos de entrenamiento de los modelos no lineales actuales que se utilizan para analizar el fenómeno de la hemodinámica cerebral.

### **3.3. Alcances y limitaciones de la solución**

A continuación se listan las limitaciones y alcances de la solución propuesta:

- Solo sujetos sanos se incluyen en el estudio.
- Para la validación del modelo se necesita de sujetos de mayor edad, además de sujetos con enfermedades cerebrovasculares.
- Se utiliza un solo segundo conjunto de datos para validación del modelo, sin embargo con esto basta para evitar el sobreajuste del modelo en la etapa de entrenamiento.
- En caso que se dispusiera de más datos para la evaluación, y dado que la AC es un proceso dinámico no estacionario, se dificultaría la evaluación del modelo con un eventual tercer conjunto de evaluación.
- La mayoría de los modelos existentes modelan la hemodinámica considerando un comportamiento lineal, a excepción de (Mitsis, 2004). y (Chacón, 2010), esto impide la comparación directa de las medidas de rendimiento de los modelos.
- En caso que se logren mejores resultados en términos de precisión y eficiencia en tiempos de entrenamiento, se puede contribuir a mejorar los índices que evalúan la autorregulación sanguínea cerebral, como el mfARI (Chacón, 2014), disminuyendo así la variabilidad de las mediciones intra e inter sujeto. Adicionalmente, se generará conocimiento respecto a que herramienta (SVM y RNP) provee mejores resultados en análisis de señales.

En cuanto a la evaluación de la solución, se tiene que existen múltiples diferencias entre los modelos actuales de la hemodinámica cerebral en cuanto a las



métricas de evaluación, por lo que no existen medidas de comparación directa para el rendimiento del modelo. Es por esta razón que se adopta la clásica medida del coeficiente de correlación entre las medidas de la VFSC y las predicciones del modelo, que es utilizada ampliamente en todos los estudios.

Adicionalmente se adopta una definición del ECMN equivalente a la adoptada por (Mitsis, 2004).

A partir de estos indicadores se podrá evaluar el modelo propuesto, para así verificar si es que es superior en términos de precisión y eficiencia al modelo actual que utiliza SVM.

## **4. Metodología, herramientas y ambiente de desarrollo**

### **4.1. Metodología a usar**

Dado que, el trabajo tiene un alto potencial investigativo procedido de una etapa experimental, el desarrollo del trabajo se basa principalmente en el método científico, por lo que se investigará inicialmente la literatura abordando exhaustivamente a las redes neuronales profundas, con sus respectivas arquitecturas que se han utilizado en el contexto de predicción de series de tiempo.

La pregunta de investigación a validar o refutar es la siguiente: ¿Pueden las RNP modelar con mayor eficiencia en tiempos de entrenamiento y precisión el fenómeno de la hemodinámica cerebral?

Para la validación o refutación de la pregunta de investigación se continúa con el diseño de la red, para lo que se deben implementar los algoritmos que se utilizan en cada capa de esta, entre los cuales se encuentra principalmente *Greedy learning* (Hinton, 2006), como se mencionó anteriormente, además en esta etapa se experimentará inicialmente con datos sintéticos previo a probar con los datos reales. Por lo tanto, para la implementación de la red se guiará el trabajo con las sugerencias de la metodología XP (*Extreme Programming*) que ya han sido probadas en el ámbito de la investigación científica (Kleb ;Wood, 2002), además de reflejar el carácter iterativo del desarrollo, ya que se deberá implementar diversas arquitecturas de RNP. A continuación se presentan los principales términos y prácticas de XP:

- Planificación.
- Release Cortos.
- Metáfora.

- Diseño simple.
- *Refactoring*.
- La programación en parejas.
- La propiedad colectiva.
- Integración Continua.
- 40 horas semanales.
- En las instalaciones del cliente.
- Estándares de Codificación.

Además se tiene en consideración que durante el desarrollo del proyecto de título también se realizarán reuniones periódicas con el profesor guía para llevar un control del progreso del trabajo y resolver dudas que puedan surgir en el camino. Estas reuniones se realizarán vía *Hangout*, dado que el profesor se encontrará fuera del país durante el semestre de desarrollo del trabajo.

## **4.2.Herramientas de desarrollo**

A nivel de software para la escritura de la memoria se utilizará el sistema operativo *OS X Yosemite 10.10.5*, y *Microsoft Office 2011 para Mac versión 14.0.0*. Para el diseño y desarrollo de los modelos se utilizará tentativamente el lenguaje *R* versión 3.2.2 con el *IDE RStudio* versión 0.99.447.

A nivel de hardware para el desarrollo del proyecto se empleará un *MacBook Pro (13-inch, Mid 2012)* con procesador *2.5 GHz Intel Core i5*, RAM de *4GB 1600 MHz DDR3* y tarjeta de vídeo *Intel HD Graphics 4000 1024 MB* (integrada).

## **4.3.Ambiente de desarrollo**

Para el desarrollo de este proyecto se trabajará en los siguientes lugares:

- Dependencias del Departamento de Ingeniería Informática, de la Universidad de Santiago de Chile.
- Domicilio particular del memorista.

Adicionalmente, para el proyecto no se depende de otras personas para obtener datos de entrada o cualquier otra dependencia que pueda retrasar el trabajo normal de la memoria.

## 5. Plan de trabajo

El plan de trabajo elaborado, considera el inicio del proyecto el día 14 de marzo de 2016 y su finalización el día 11 de julio de 2016, intentando coincidir con el periodo lectivo del primer semestre del año 2016 de la Universidad de Santiago de Chile. De esta manera, el desarrollo del proyecto comprende una duración total de 17 semanas (correspondiente a un periodo lectivo normal).

Para cumplir con la dedicación efectiva de 612 horas, se considera un trabajo de 6 horas diarias durante 6 días a la semana (lunes a sábado).

La planificación se divide esencialmente en tres etapas: investigación, desarrollo (utilizando la metodología XP) y finalmente la documentación de la memoria. El detalle de la planificación se adjunta en el Apéndice al final del presente.

**Tabla 5.1: Resumen planificación del proyecto**

Hito	Inicio	Término
<b>Etapas de investigación</b>	03/14/2016	04/06/2016
<b>Etapas de desarrollo</b>	04/07/2016	06/30/2016
<b>Etapas de documentación</b>	07/01/2016	08/02/2016

## 6. Referencias

Batres-Estrada, G. (2015). *Deep Learning for Multivariate Financial Time Series*. Royal Institute of Technology, Engineering & Physics, Stockholm.

Burgos Molina, C., & Chacón, M. (2014). *Entrenamiento muestral de modelos dinámicos con SVM*. Universidad de Santiago de Chile, Departamento de Ingeniería Informática, Santiago.

Chacón, M., Araya, C., & Panerai, R. (30 de septiembre de 2010). Non-linear multivariate modeling of cerebral hemodynamics with autoregressive Support Vector Machines. *Medical Engineering & Physics*, 33, 180-187.

Chacón, M., Jara, J., & Panerai, R. (14 de octubre de 2014). A New Model-Free Index of Dynamic Cerebral Blood Flow Autoregulation. (Y. Hoshi, Ed.) *PLOS ONE*, 9(10), 0108281.

Chacon, M., Panerai, R., Araya, C., & Muñoz, M. (2009). Comparison Between SVM and ANN for Modeling the Cerebral Autoregulation Blood Flow System.

- International Joint Conference on Computational Intelligence. Madeira: Springer 522-525
- Hinton, G., & Osindero, S. (2006). A fast learning algorithm for deep belief nets. *Neural Computation*, 18, 1527-1554.
- Liu, J., Hu, Y., Jia, J., & Chan, P. (2014). *Deep Neural Network Based Feature Representation for Weather Forecasting*. The Hong Kong Polytechnic University, Department of Computing, Hong Kong.
- Markwalder, T., Grollmund, P., Seiler, R., Roth, F., & Aaslid, R. (1984). Dependency of blood flow velocity in the middle cerebral artery on end-tidal carbon dioxide partial pressure: a transcranial ultrasound Doppler study. *Journal of Cerebral Blood Flow & Metabolism*, 4, 368-72.
- Mitsis, G., Poulin, M., Robbins, P., & Marmarelis, V. (2004). Nonlinear modeling of the dynamic effects of arterial pressure and CO<sub>2</sub> variations on cerebral blood flow in healthy humans. *IEEE Transactions Biomedical Engineering*, 51, 1932-43.
- Oberreutera, G. (2014). Accidente cerebrovascular isquémico en pacientes con trombo intracavitario: Experiencia con tratamientos distintos en fase aguda. *Revista Médica de Chile*, 142, 90-94.
- Panerai, R. (30 de Octubre de 1997). Assessment of cerebral pressure autoregulation in humans—a review of measurement methods. *IOPscience*, 305-338.
- Panerai, R., Simpson, D., Deverson, S., Mahony, P., Hayes, P., & Evans, D. (2000). Multivariate dynamic analysis of cerebral blood flow regulation in humans. *IEEE Transactions Biomedical Engineering*, 47, 419-23.
- Paulson, O., Strandgaard, B., & Edvinsson, L. (1990). Cerebral autoregulation. *Cerebrovascular Brain Metab Rev*, 2, 161-92.
- Rivero, M., & Boto, G. (2007). Monitorización de la presión intra- craneal en el trauma craneoencefálico grave. En B. G. Vaquero Crespo J, *Daño cerebral postraumático*, 147-57. Madrid: Mapfre S.A.
- Schölkopf, B., Smola, A., Williamson, R., & Bartlett, P. (1998). New support vector algorithms. *Neural Comput*, 12, 1083-121.

- Simpson, D., Panerai, R., Evans, D., Garnham, J., Naylor, A., & Bell, P. (2000). Estimating normal and pathological flow velocity to step changes in end-tidal pCO<sub>2</sub>. *Medical & Biology Engineering & Computing*, 38, 535-9.
- Tiecks, F. M., Lam, A. M., Aaslid, R. P., & Newell, D. M. (1995). Comparison of Static and Dynamic Cerebral Autoregulation Measurements. *Stroke*, 26, 1014-1019.
- Torbey, M., & Bhardwaj, A. (2004). Cerebral blood flow physiology and monitoring. En J. I. Suárez, *Critical care neurology and neurosurgery*. New Jersey: Human Press, 23-27.
- Vapnik, A., Golowich, S., & Smola, A. (1997). Support vector method for function approximation. Regression estimation, and signal processing. *Neural information processing systems*. 9, 281-7. Cambridge: MIT Press.
- Wood, W., & Kleb, W. (2002). Extreme Programming in a Research Environment. En L. W. Don Wells, *Extreme Programming and Agile Methods — XP/Agile Universe 2002*, 2418, 89-99. Hampton, USA: Springer Berlin Heidelberg.

## 7. Apéndice

### 7.1.Glosario

RNP: es la evolución de las redes neuronales convencionales, en las que se trabaja con más capas ocultas (generalmente 8).

SVM: máquina utilizada dentro de Machine Learning con un conjunto de algoritmo de aprendizaje supervisado, empleada en el contexto de problemas de clasificación.

v-SVM: máquina utilizada dentro de Machine Learning con un conjunto de algoritmo de aprendizaje supervisado, empleada en el contexto de problemas de regresión.

Machine Learning: es un área de estudio en la que se desarrollan técnicas para que las computadoras aprendan comportamientos a partir de los datos.

AC: conjunto de mecanismos fisiológicos que se encargan de mantener la presión sanguínea en un nivel adecuado.

RN: redes neuronales convencionales.

PAM: presión arterial media.

$PaCO_2$ : presión parcial de dióxido de carbono en sangre arterial.

VFSC: velocidad del flujo sanguíneo cerebral.

FSC: flujo sanguíneo cerebral.

$EtCO_2$ : nivel de dióxido de carbono liberado al fin de una exhalación.

## 7.2. Enfoques de solución

En la literatura se han abordado múltiples enfoques para modelar la hemodinámica cerebral, pero solamente dos lo han realizado considerando un comportamiento no lineal, en primera instancia se realizó con RN (Mitsis, 2004) y actualmente se encuentra una v-SVM (SVM utilizada para problemas de regresión) ya que ofrece mejores resultados en términos de ajuste que las RN (Chacon, 2009; Chacon, 2010). Con el apareamiento de las RNP, surge la interrogante de si se podría modelar de mejor forma el fenómeno dinámico de la hemodinámica cerebral en términos de precisión y eficiencia. De esta forma se describirá brevemente el enfoque basado en SVM y el que se propone utilizando RNP.

El algoritmo adoptado por Vapnik et al. para la SVM es denominado v-SVM (Vapnik, 1997). Este algoritmo está basado en la teoría de aprendizaje estadística, que aborda el problema de regresión ajustando un tubo de radio  $\varepsilon$  a los datos (Schölkopf, 1998). La frontera de decisión para determinar el radio del tubo, está dada por un subconjunto pequeño de ejemplos de entrenamiento llamados vectores de soporte. La principal ventaja que posee la SVM es que logra encontrar el mínimo global en la superficie de error, por lo que obtiene valores óptimos, sin embargo para lograr esto necesita de mucho tiempo y recursos computacionales (Burgos, 2014). Adicionalmente la SVM no posee un modelo con recurrencias internas para representar fenómenos dinámicos en el tiempo, por lo que para lograr esto utiliza recurrencias externas con retardos de tiempo (Burgos, 2014).

Las nuevas RNP poseen características distintivas de las convencionales RN. Una de estas, es que para las RNP se ha logrado abordar el problema del entrenamiento en modelos con recurrencias internas introduciendo la Máquina Restrictiva de *Boltzmann* con un algoritmo de aprendizaje denominado *Greedy learning* (Hinton,

2006). El aprendizaje en estos modelos se puede llevar a cabo en redes de creencias altamente conectadas de manera rápida (Hinton, 2006).

Las RNP de creencias para aprender de manera eficiente un modelo complicado, combina un conjunto de modelos más sencillos que aprenden de manera secuencial. De esta manera se puede obtener un mejor rendimiento en el espacio de características aprendido (Liu, 2014). Las ventajas de las RNP contra la SVM está en que se ha logrado generar un algoritmo de aprendizaje en modelos con recurrencias internas, lo cual tal vez podría modelar de manera más eficiente y precisa fenómenos dinámicos en el tiempo como la hemodinámica cerebral. Sin embargo, las RNP aún poseen el problema de los mínimos locales, pero puede ser abordado con un modelo de aprendizaje profundo que puede incluir una SVM en la capa superior de aprendizaje (Liu, 2014).

### **7.3. Justificación del enfoque seleccionado**

De los enfoques mencionados anteriormente se escoge las RNP. Esto dado que el surgimiento de estas redes ha generado la duda de si podrían modelar de manera más eficiente y precisa la hemodinámica cerebral.

Las RNP se han utilizado para modelar fenómenos dinámicos en el tiempo utilizando recurrencias internas para el modelamiento, ejemplos de esto son la predicción de datos financieros (Batres-Estrada, 2015) y la predicción del clima (Liu, 2014). En el último caso se modela una RNP con una SVM en la capa superior de aprendizaje, obteniendo un modelo con mejor ajuste que la clásica SVM. De esta manera se posee información que motiva la decisión de modelar la hemodinámica cerebral utilizando RNP, para comparar los resultados que se generen con la actual SVM que posee los mejores resultados.

### **7.4. Carta gantt**

La diferencia que se da entre la fecha de término del proyecto propuesta para el 11 de julio, contra el 2 de agosto que aparece en la carta gantt, se da por los días libres (domingo), de lo contrario la planificación no sumaría 102 días.

Las pruebas descritas en la etapa de desarrollo corresponden a la implementación respectiva de las diferentes arquitecturas estudiadas, y se escogerá la que entregue mejores resultados. Adicionalmente se considera dos etapas de validación de los modelos, donde se realizará análisis estadísticos e interpretación de resultados principalmente.

☐ Proyecto de título	<b>102d</b>	03-14-2016	08-02-2016
☐ Etapa de investigación	<b>18d</b>	03-14-2016	04-06-2016
Revisión de literatura	6d	03-14-2016	03-21-2016
Estudio de arquitecturas de redes neuronales profundas	6d	03-22-2016	03-29-2016
Definir arquitectura	2d	03-30-2016	03-31-2016
Etapa de herramienta de desarrollo	3d	04-01-2016	04-05-2016
Definir herramienta de desarrollo	1d	04-06-2016	04-06-2016
☐ Etapa de desarrollo	<b>61d</b>	04-07-2016	06-30-2016
Análisis de datos	6d	04-07-2016	04-14-2016
Análisis de modelos no lineales a utilizar	3d	04-15-2016	04-19-2016
Selección de modelos no lineales	2d	04-20-2016	04-21-2016
☐ Prueba 1	<b>9d</b>	04-22-2016	04-30-2016
Diseño de modelo	2d	04-22-2016	04-23-2016
Implementación modelo	4d	04-25-2016	04-28-2016
Análisis resultados	2d	04-29-2016	04-30-2016
Decidir validez del modelo	1d	05-01-2016	05-01-2015
☐ Prueba 2	<b>9d</b>	05-02-2016	05-09-2016
Diseño de modelo	2d	05-02-2016	05-03-2016
Implementación modelo	4d	05-04-2016	05-07-2016
Análisis resultados	2d	05-08-2016	05-09-2016
Decidir validez del modelo	1d	05-10-2016	05-10-2016
☐ Prueba 3	<b>9d</b>	05-11-2016	05-19-2016
Diseño de modelo	2d	05-11-2016	05-12-2016
Implementación modelo	4d	05-13-2016	05-16-2016
Análisis resultados	2d	05-17-2016	05-18-2016
Decidir validez del modelo	1d	05-19-2016	05-19-2016
☐ Validación 1	<b>18d</b>	05-20-2016	06-14-2016
Análisis estadístico modelos	5d	05-20-2016	05-23-2016
Validación de los modelos	6d	05-24-2016	05-29-2016
Comparación de los modelos	2d	05-30-2016	05-31-2016
Corrección de posibles errores	5d	06-04-2016	06-14-2016



<input type="checkbox"/> Validación 2	<b>16d</b>	06-15-2016	06-30-2016
Análisis estadístico modelos	2d	06-15-2016	06-21-2016
Validación de modelos	5d	06-22-2016	06-26-2016
Comparación de los modelos	2d	06-27-2016	06-28-2016
Corrección de posibles errores	2d	06-29-2016	06-30-2016
<input type="checkbox"/> Etapa de documentación	<b>23d</b>	07-01-2016	08-02-2016
Escritura de la memoria	7d	07-01-2016	07-11-2016
Correcciones del informe	5d	07-12-2016	07-18-2016
Revisión del informe	4d	07-18-2016	07-21-2016
Desarrollar presentación de la memoria	6d	07-22-2016	07-29-2016
Revisión de la presentación	2d	08-01-2016	08-02-2016